PA2 d'Informatique - X08

Contrôle écrit : Réseaux, protocoles (INF 566)

Mercredi 16 mars 2011

Le contrôle dure 3h. Les documents sont autorisés. Notation sur 21.

Question 1 : Débit de transmission (2 points)

Une entreprise désire réaliser la sauvegarde de ses données sur un site distant. Le volume de données à sauvegarder est estimé à 10Go/jour. La sauvegarde doit s'effectuer la nuit, de 22h00 à 6h00. Les deux sites sont reliés par une ligne à 2Mbits/s. On vous demande de vérifier si cette solution est réalisable et, le cas échéant, de proposer une solution qui permette cette sauvegarde. Pour ce problème, on admettra que $1Kb = 10^3$ bits.

Question 2 : Efficacité du protocole CSMA (3 points)

On se propose de calculer l'efficacité du protocole CSMA *p*-persistant. Dans cette version, le temps est divisé en intervalles de temps de durée égale appelés « slots ». Les stations sont autorisées à transmettre uniquement au début d'un slot. Une station ayant un paquet à transmettre procède alors selon l'algorithme suivant (on néglige les autres aspects du protocole) :

1. Si le canal est libre, transmettre le paquet avec une probabilité $p \in]0,1[$ indépendamment des autres stations, et reporter la transmission d'un slot avec une probabilité $(1-p)$.
2. Si le canal est occupé, attendre jusqu'à ce qu'il soit libre puis aller à l'étape 1.
3. Si la transmission est retardée d'un slot, aller à 1.

Soient N (» 1) le nombre des stations du système, τ le temps de transmission d'un paquet (tous les paquets ont la même taille) et δ le délai de propagation maximal du canal (i.e. entre les deux stations les plus éloignées). On définit le paramètre $a = \delta/\tau$. La durée du slot est égale à 2δ. On définit l'efficacité E du protocole comme étant la fraction de temps pendant laquelle les stations peuvent émettre de nouveaux paquets en cas de charge élevée imposée par les stations (i.e. toutes les stations ont tout le temps de nouveaux paquets à transmettre).

a) Pourquoi selon vous la durée du slot est égale à 2δ ?
b) Considérons que le canal est libre. Soit $\pi(p)$ la probabilité qu'il y ait une transmission réussie le prochain slot. Montrer que $\pi(p) = Np(1-p)^{N-1}$.
c) On considère que les stations connaissent N. Pour maximiser π on choisit alors $p = 1/N$. Calculer la valeur maximale $\pi_{max} = \pi(1/N)$ pour N très grand. Calculer en fonction de π_{max}, le nombre moyen de slots perdus avant une retransmission réussie.
d) En déduire que $E = 1/(1+2(e-1)a)$. (e étant la base du logarithme népérien).

Question 3 : Questions IPv6 (3 points)

1) Indiquer parmi les représentations suivantes lesquelles correspondent à des adresses de hôte IPv6 correctement formatées (il peut y avoir plusieurs) ?
A. 2001:0db8:0000:0000:0000:0000:1428:57ab
B. 2001:0db8::1428:57ab
C. 2001::1685:2123::1428:57ab
D. 2001:99:ab:1:99:2:1:9
E. 2001:1428:57ab:1685:2123:1428:57ab
F. 2001:1428:57ab:1685/64

2) Est ce que les études montrent qu'il y a plus d'équipements connectés à Internet que d'adresses IPv4 ? Si oui, identifier au moins une façon de réaliser cela.

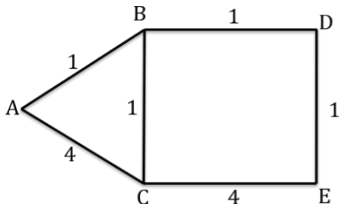
3) Vrai ou Faux ? Avec IPv6 on peut adresser 4 fois plus d'équipements qu'avec IPv4.

4) Selon le RFC 5218 « Qu'est ce qui produit un protocole réussi » (What Makes for a Successful Protocol?), quelle est l'importance du critère « avoir une bonne conception technique » comparé aux autres critères ?

5) Dans IPv4, si un paquet est trop long pour être transmis sur le lien sous-jacent, le routeur pourrait fragmenter le paquet en des paquets IP plus petits. Est-ce que IPv6 fonctionne comme IPv4 sur ce point là ? Sinon, comment le routeur gère le cas où un paquet IPv6 est trop long pour être transmis ?

Question 4 : Routage par vecteur de distance (3 points)

Considérons le réseau de la figure ci-dessous. On utilise la technique dite vecteur de distance entre les routeurs A, B, C, D et E.



1. On considère d'abord qu'on utilise la technique de base sans aucune amélioration. Au démarrage, les nœuds envoient leurs vecteurs de distance (VD) dans l'ordre suivant : à t=0, pour A; à t=5sec pour B, à t =10sec pour C; à t=15sec pour D ; à t=20sec pour E. Puis le même cycle est répété toutes les 30 secondes. Quels sont les vecteurs de distance initiaux (i.e. avant le démarrage) des nœuds, et quels sont leurs VD finaux (i.e. après la convergence).
2. Considérons maintenant que la technique de l'horizon partagé avec retour empoisonné est utilisée *pour toute la suite*. En quoi consiste cette technique ? Et à quoi sert-elle ? Après convergence du système : quel sera le VD envoyé par D à B? et le VD envoyé par E à C?
3. A l'instant t = 102 sec, le lien BA tombe en panne (et ne sera plus restauré). Décrire ce que se passe jusqu'à la convergence. Est ce qu'il y aura comptage jusqu'à l'infini ?
4. A l'instant t = 287 sec, le lien CA tombe aussi en panne. Décrire ce qui se passe jusqu'à la convergence. (Les nœuds gardent le même cycle d'envoi des VD sauf que A disparaît).
5. On considère que l'option « *triggered updates* » est supportée aussi. Que se passera-t-il alors après la panne du lien CA à t=287 sec ? Expliquer l'origine du problème. Dire si la version DUAL permet d'y pallier, et si oui comment ?

Question 5 : Routage BGP (3 points)

Selon le protocole BGP, les routeurs de bordure s'échangent les annonces de routes qui contiennent un préfixe et un chemin d'AS. La sémantique d'une route annoncée par un routeur à son voisin est alors : j'accepte de relayer le trafic en provenance de ta part vers le réseau identifié par le préfixe ci-joint et selon le chemin d'AS indiqué. Comme on a vu dans le cours, il y a trois étapes pour traiter les annonces de routes : d'abord la politique d'import de routes qui consiste à déterminer les routes à ne pas prendre en considération, le processus de décision qui consiste à ordonner les routes et choisir la meilleure route qui sera alors adoptée et la politique d'export qui consiste à choisir vers quels voisins annoncer la route adoptée. Pour réaliser une politique de routage, les routeurs BGP peuvent contrôler n'importe laquelle de ces trois étapes : modifier la politique d'import pour écarter des routes qu'ils ne veulent pas utiliser, modifier certains attributs pour choisir certaines routes plutôt que d'autres, décider de ne pas exporter des routes vers certains voisins.

1. Que signifie un lien de « transit entre client et fournisseur » entre deux systèmes autonomes ? Et un lien de « *peering* »?

2. Expliquer comment les règles de d'import de routes (*customer* > *peer* > *provider*) et d'export de routes dans les routeurs BGP (expliquées dans le cours) permettent de tenir compte des relations commerciales entre clients et fournisseurs.

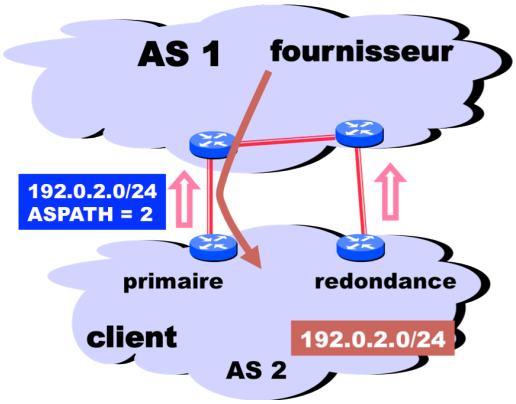


Figure (a)

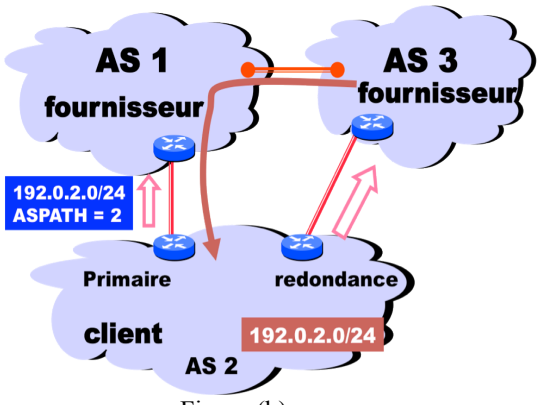


Figure (b)

3. Soit le réseau de la figure (a) ci-dessus. L'accord entre le client et le fournisseur stipule que le trafic vers le réseau du client devrait traverser le lien primaire sauf en cas de panne. Dans ce cas là, le lien de redondance sera utilisé. Comment refléter cela dans l'annonce de route par le routeur du client relié au lien de redondance ? (Penser à utiliser un des trois attributs LOCAL_PREF, AS_PATH ou MED).
4. Considérer maintenant le réseau de la figure (b) ci-dessus. Les deux fournisseurs AS1 et AS3 ont un accord de « *peering* ». Le client annonce son préfixe aux deux fournisseurs. Afin de refléter le fait que le lien vers AS3 devrait être utilisé en cas de redondance, le client choisit d'adopter la même solution que la question 3 (figure (a) avec un seul fournisseur). Est ce que cette solution marche dans ce cas là ? (Pensez à l'ordre de priorité des règles d'import et de sélection des routes).
5. A quoi sert l'attribut MED (*Multi Exit Discriminator*) ?

Question 6 : Contrôle de congestion TCP (4points)

Le contrôle de congestion dans TCP a été déterminant pour le succès de l'Internet. L'objectif du contrôle de congestion est d'utiliser le réseau de façon efficace (augmenter le débit des sources de sorte à maximiser l'utilisation des ressources du réseau) et équitable (attribuer à chaque connexion TCP une part des ressources du réseau la plus proche possible des autres connexions). La difficulté réside dans l'hétérogénéité des chemins pour les différentes connexions TCP en terme de *bande passante disponible*, de *délai aller retour (RTD)* et de *taux d'erreur de bit*.

1) Expliquer en quoi cette hétérogénéité rend difficile la réalisation des deux objectifs (efficacité et équité) du contrôle de congestion TCP ?

L'introduction de liens à très haut débit dans l'Internet exacerbe le problème de sous-utilisation des ressources du réseau en cas de faible charge. Plusieurs nouvelles versions de TCP ont été proposées avec en particulier la modification de la fonction d'augmentation de la fenêtre de sorte à 'récupérer rapidement' des ressources libres dans le réseau. Un des problèmes concernant ces versions 'haut débit' de TCP réside dans la cohabitation avec les connexions TCP standards (ne supportant pas cette amélioration). Il faudrait en fait que les versions 'haut débit' agissent de façon équitable avec les connexions TCP standards en cas de taux de perte élevé (réseau sur-utilisé), tout en permettant une meilleure utilisation des ressources en cas d'un faible taux de perte. Une des versions TCP haut débit, BIC-TCP (Binary Increase Congestion control – TCP) fonctionne comme suit : quand une source BIC détecte une perte de paquet, elle réduit la fenêtre par un facteur multiplicatif β. Deux paramètres sont définis : W_{max} initialisé à la taille de la fenêtre juste avant la perte et W_{min} initialisé à la valeur de la fenêtre après la réduction. La fenêtre après la réduction sera donc égale à $W_{min} = W_{max} - \beta W_{max} = (1-\beta) W_{max}$. Puis BIC effectue une recherche binaire en 'sautant' directement à mi-parcours entre W_{max} et W_{min}. Cette augmentation pourrait être trop grande en un seul RTT. Alors, si ce saut est plus important qu'un seuil maximum S_{max}, la fenêtre est augmentée linéairement de S_{max}. S'il n'y a pas de perte de paquets, la valeur de la fenêtre est considérée comme la nouvelle valeur de W_{min}. S'il y a eu perte de paquet, la valeur de la fenêtre devient la nouvelle valeur de W_{max}. Ce processus continue jusqu'à ce que l'incrément de la fenêtre devienne inférieur à un seuil S_{min}. A ce moment là, la fenêtre devient égale à W_{max}. La fonction d'augmentation de la fenêtre sera donc très probablement au début linéaire (linear increase) puis logarithmique (binary search). Au delà de W_{max} la fonction d'augmentation de la fenêtre est symétrique de celle utilisée avant d'atteindre W_{max} et vise à trouver le nouveau maximum (Max probing) : d'abord une phase d'augmentation lente afin de trouver le maximum proche de la valeur actuelle de W_{max}, puis une phase linéaire avec un incrément important. Voir la figure 1 à la page suivante.

2) Dire pourquoi cette fonction d'augmentation permet d'améliorer l'efficacité de TCP en cas de liens haut débit, sans trop dégrader l'équité vis à vis des connexions TCP standards.

3) Comparer le fonctionnement de deux connexions BIC : la première fonctionnant entre une source et une destination reliées par lien ayant un délai de propagation de 1ms et une capacité de 1 Gbps et la deuxième entre une source et une destination reliées par lien ayant un délai de propagation de 100 ms et une capacité de 1 Gbps. Qu'en déduisez-vous ?
4) La version CUBIC de TCP permet d'améliorer l'équité entre les connexions ayant des RTTs différents en adoptant une fonction d'augmentation de la fenêtre cubique en fonction du temps et indépendamment des ACKs reçus : $W_{cubic} = C(t - K)^3 + W_{\max}$ où t est le temps écoulé depuis la dernière réduction de la fenêtre, C étant un facteur d'échelle, $K^3 = \beta W_{\max}/C$, (β et $W_{\max}$ ayant la même définition que BIC)[1]. Voir la figure 2 ci-dessous. Comment est ce que cette technique permettrait elle d'assurer l'équité entre deux connexions TCP-Cubic ayant des valeurs de fenêtres différentes à un moment donné, ainsi qu'entre les connexions ayant des RTT différents ?

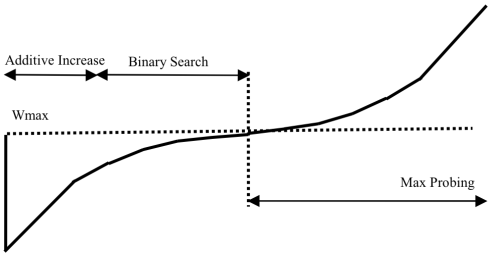


Fig. 1: The Window Growth Function of BIC

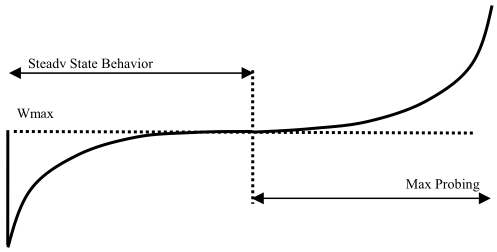
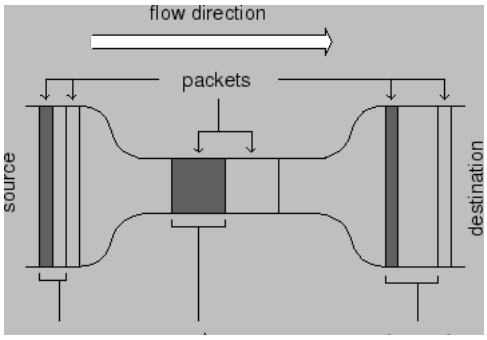


Fig. 2: The Window Growth Function of CUBIC

Question 7 : Qualité de service dans l'Internet (3 points)



La technique « packet pair » (PP) permet de mesurer la capacité du goulot d'étranglement d'un chemin entre une source et une destination, dans le cas où les routeurs du réseau utilisent la politique de service FIFO. Cette technique consiste à envoyer deux paquets de même taille s et à mesurer leur temps de réception à la destination. Soit t_e^0 et t_e^1 les temps d'envoi des deux paquets par la source et t_r^0 et t_r^1 les temps de réception de ces deux paquets par la destination. Soit B la capacité du goulot d'étranglement. Voir la schématisation dans la figure ci-dessus.

1) Trouver une relation entre ces paramètres.
2) Sachant que les deux paquets sont envoyés immédiatement l'un après l'autre, simplifier la relation et trouver B en fonction de s et des temps de réception des paquets.
3) Supposons maintenant que les routeurs du réseau implémentent la politique FQ. Que permet de mesurer la technique PP ?

[1] Que représente K ? Vérifier la relation $K^3 = \beta W_{\max}/C$. (Question hors examen).

Corrigé Exam X08, INF566, 16 mars 2011

Question 1 :
2Mbps => il faudrait 4.10^4 s ≈ 11h pour la sauvegarde. Ce n'est donc pas réalisable.
On pourrait les mettre sur une clé USB et les transporter en voiture.

Question 2 :

a) On utilise une durée de slot de 2δ afin de garantir que, si deux stations choisissent de transmettre au début de deux slots différents, elles ne puissent pas avoir une collision.

b) Pour qu'il y ait transmission réussie il faut qu'une station émette et qu'il n'y ait pas de collision. La probabilité qu'une station donnée émette et que les autres stations n'émettent pas étant $p(1\text{-}p)^{N-1}$, et comme il y a N façons exclusives qu'une station émette et que les autres N-1 stations n'émettent pas, alors la probabilité qu'une station quelconque émette et que les autres stations n'émettent pas est alors $\pi(p) = Np(1\text{-}p)^{N-1}$.

c) $\pi(1/N) = (1\text{-}1/N)^{N-1} = 1/e$ pour N très grand. Soit A le nombre moyen de slots perdus avant une transmission réussie. Avec une probabilité π le premier slot correspond à une transmission réussie, et il n'y aura donc pas de slot perdu. Avec une probabilité 1 - π le premier slot est perdu et on est revenu à la situation initiale et l'algorithme perdra alors A slots en moyenne en plus du premier donc : $A = \pi \cdot 0 + (1 - \pi).(1+A)$. Cela donne $A = (1\text{-}\pi)/\pi = e - 1$.

d) Chaque transmission réussie (de durée τ) sera donc accompagnée de A slots de durée totale $2(e\text{-}1)\delta$. L'efficacité $E = \tau/(\tau+2(e\text{-}1)\delta) = 1/(1+2(e\text{-}1)a) \approx 1/(1+3.4a)$.

Question 3 :

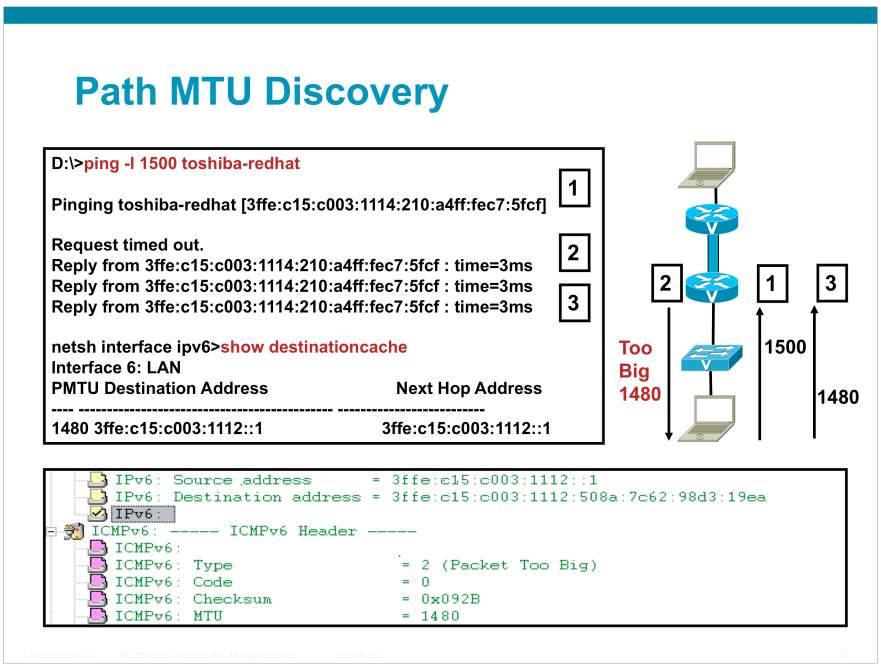
1) Answer: A, B, D

2) Answer: More (5 billion in 2010, 4 billion IPv4 addresses). NAT or NAPT (Network Address, and Port, Translation) is the most obvious method to help achieve this. Others are short IP leases, network virtualization, etc.

3) False. IPv4 has 2^{32} addresses, IPv6 has 2^{128} addresses

4) Not important compared to others. From RFC 5218 section 2.1.7: "experience shows that good technical design has minimal impact on initial success compared with other factors."

5) Answer: Unlike IPv4, Per-hop fragmentation does not exist in IPv6. A router must perform Path MTU discovery (described on Page 6 of "03-townsley-x-lecture-ipv6-basics.pdf")



Question 4 :

1) Avant démarrer l'algorithme on connaît les voisins donc les VD initiaux seront :
   A : [(A,0),(B,1),(C,4),(D,U),(E,U)] (U signifie *unreachable*)
   B : [(A,1),(B,0),(C,1),(D,1),(E,U)]
   C : [(A,4),(B,1),(C,0),(D,U),(E,4)]
   D : [(A,U),(B,1),(C,U),(D,0),(E,1)]
   E : [(A,U),(B,U),(C,4),(D,1),(E,0)].
   Et après la convergence ils seront :
   A : [(A,0),(B,1),(C,2),(D,2),(E,3)]
   B : [(A,1),(B,0),(C,1),(D,1),(E,2)]
   C : [(A,2),(B,1),(C,0),(D,2),(E,3)]
   D : [(A,2),(B,1),(C,2),(D,0),(E,1)]
   E : [(A,3),(B,2),(C,3),(D,1),(E,0)].

2) La technique de l'horizon partagé avec retour empoisonné est une méthode pour éviter les boucles de routage dans les protocoles à vecteur de distance. Elle consiste à interdire à un routeur d'annoncer une route sur l'interface (i.e. à un voisin) par laquelle il a appris cette route.
   Vecteur de distance de D à B : [(A,U),(B,U),(C,U),(D,0),(E,1)]
   Vecteur de distance de E à C : [(A,3),(B,2),(C,3),(D,1),(E,0)].

3) C envoie son VD à t = 100, puis AB tombe en panne à t = 102. Le prochain est D (à t = 105) qui enverra à B le vecteur indiqué ci-dessus (et à E un autre vecteur). La technique de split horizon with poisonous reverse a permis ici d'éviter la formation d'une boucle car D n'annonce pas la 'joignabilité' de A. Puis, à t = 110, E envoie le VD indiqué ci-dessus à C. Cela ne change rien pour C car les distances annoncées ne sont pas inférieures à celles dont il dispose actuellement. A t = 120 le nœud A annonce à C le vecteur suivant : [(A,0),(B,U),(C,4),(D,U),(E,U)] (pour D et E ils sont annoncés comme U car A garde l'information que le routage vers ces deux nœuds était via B car on applique la technique de l'horizon partagé avec retour empoisonné. Le vecteur de B vers C et D ne provoquera pas ne plus une boucle. Dans ce cas, la technique aura réussi à éviter le comptage à l'infini.

4) A t = 290, E enverra le VD suivant à C : E : [(A,7),(B,2),(C,3),(D,1),(E,0)]. C croit alors qu'il y a une route vers A via E. Il y a donc comptage jusqu'à l'infini.

5) Si l'option triggered updates est supportée, C informera immédiatement B et E de la panne du lien AC. Mais ceci n'aurait pas changé grand-chose car E route vers A via D et non via C. Donc E continuera à penser qu'il y a une route vers A et il y a aura toujours comptage à l'infini. La méthode DUAL consiste à stopper momentanément l'envoi régulier des VD (afin d'éviter la propagation de fausses informations), s'assurer que tous les routeurs concernés ont été informés du changement (la panne) puis reprendre l'envoi habituel des VD aux voisins. Cette technique consiste donc à faire ponctuellement de la 'diffusion' (technique utilisée en général dans l'approche LS) afin d'avoir la cohérence des tables de routage au plus vite.

Question 5 :

1) Lien provider-customer transit (aka "transit") : it is an inter-AS interconnection link where one ISP (the "provider") provides access to all (or most) destinations in its routing tables to another ISP (the "customer"). Transit almost always is meaningful in an inter-AS relationship where financial settlement is involved; the provider charges its customers for Internet access, in return for forwarding packets on behalf of customers to destinations (and in the opposite direction in many cases).
   Lien peering : it is an inter-AS interconnection link where two ASes (typically ISPs) provide mutual access to a subset of each other's routing tables. The subset of interest here is their own transit customers (and the ISPs own internal addresses). Like transit, peering is a business deal, but it may not involve financial settlement. While paid peering is common in some parts of the world, in many cases they are reciprocal agreements. As long as the traffic ratio between the concerned ASs is not highly asymmetric (e.g., 4:1 is a commonly believed and quoted ratio), there's usually no financial settlement. Peering deals are almost always under non-disclosure and are confidential.
2) Importer une route (vers un préfixe) signifie préférer de router les données vers ce préfixe via l'AS qui nous a annoncé la route. Dans le cas où plusieurs AS voisins annoncent des routes vers un même préfixe, la règle de préférence locale stipule qu'il est préférable d'utiliser la route qui passe par le client (car ceci revient à générer

des revenus pour l'ISP) puis par le peer (car ceci n'implique pas de charge financière en général et enfin celle qui passe par le fournisseur car cela induit une charge financière.
Quant à l'export des routes : exporter une route vers un AS signifie qu'on accepte de relayer les données vers le préfixe annoncée en provenance de l'AS vers lequel on a exporté la route. Pour cela, on exporte les routes annonçant les préfixes de nos clients vers tous les AS voisins (on est payé pour cela), on exporte les routes annonçant les préfixes de notre AS (nos propres client directs) à tous les AS voisins (on veut maximiser leur joignabilité), on exporte les routes annoncées par notre fournisseurs uniquement à nos clients (nous ne sommes pas censés servir de passage des autres AS vers notre fournisseur, mais en même temps on aimerait améliorer la connectivité de nos clients), on exporte les routes annoncées sur les liens de peering uniquement à nos clients afin d'améliorer leur connectivité. Il n'est pas autorisé d'informer d'autres AS des routes apprises via les liens de peering.

3) Le processus de décision BGP consiste à parcourir les attributs des routes dans un certain ordre afin de choisir la meilleure route. L'ordre est indiqué dans le slide Route Selection Summary du cours sur BGP : d'abord Highest Local Preference (Customer > peer > provider), puis Shortest AS_PATH, puis Lowest MED. Comme l'AS1 est fournisseur de l'AS2, les routes annoncées par les deux routeurs connectés aux liens primaire et back-up auront la même LOCAL_PREF (route vers préfixe client). Le prochain attribut sera donc AS_PATH : il faudrait que la longueur du chemin du lien primaire soit 'plus petite aux yeux de BGP' que celle du lien back-up. D'où l'idée de faire du padding ou bien AP_PATH prepending qui consiste à répéter le nom de l'AS plus qu'une fois dans le chemin afin de le rallonger pour BGP. Cette technique permet de maintenir la scalabilité du routage BGP car on ne gère pas les distances IGP à l'extérieur de l'AS. Dans notre cas, le routeur du client relié au lien de redondance annoncera par exemple la route : 192.0.2.0/24 ASPATH=2 2 2.
4) Dans ce cas, AS3 et AS1 sont tous les deux fournisseurs de AS2. Le lien de peering entre AS3 et AS1 devrait en théorie permettre l'envoi des données en provenance de AS3 vers AS2 via le lien de peering, vers AS1 puis vers leur destination AS2. Si maintenant on annonce la route de back-up vers AS3, celui-ci préférera de passer par le lien de back-up même si AS1 lui a annoncé le préfixe 192.0.2.0/24 ASPATH= 1 2 et qu'il ait reçu sur le lien back-up 192.0.2.0/24 ASPATH=2 2 2 *avec un chemin plus long* tout simplement car l'attribut LOCAL_PREF est regardé en priorité AVANT l'attribut AS_PATH et AS3 choisira de passer par la route annoncée par son client même s'il dispose d'une route plus 'courte'. La solution à ce problème est dans l'utilisation de l'attribut Community. (A vous de regarder si cela vous intéresse).
5) MED est utilisé dans le cas d'un trafic *asymétrique* par un client pour indiquer à son fournisseur de transporter la réponse (volumineuse) à une requête (de petite taille, http par exemple) dans son réseau plutôt que de s'en débarrasser comme on le fait d'une patate chaude au plus vite en l'envoyant vers le premier routeur accessible du réseau du client. Le client indique alors par cet attribut sa préférence pour recevoir la réponse à une requête à travers un routeur spécifique parmi deux ou plusieurs routeurs entre un client et un fournisseur.

Question 6 :

1) Hétérogénéité dans le bande passante disponible : le fait qu'il y ait des liens à haut débit et des liens à débit moins élevé pose le problème de montée en charge. Si la source TCP augmente rapidement la fenêtre afin d'exploiter rapidement les ressources disponibles sur un lien à haut débit, cette augmentation risque de provoquer des pertes de congestion sur les liens à débit moins élevé.
Hétérogénéité dans les délais aller-retour : l'incrémentation de la fenêtre est rythmée par le retour des ACKs. Plus le RTT est petit, plus la source récupère rapidement les ressources disponibles ce qui va à l'encontre de l'objectif d'équité.
Hétérogénéité dans les taux d'erreur de bit : des pertes de paquets dues à la *corruption* pourront être considérées comme signal de *congestion* ce qui empêcherait les sources d'exploiter efficacement les ressources du réseau.
2) BIC uses the technique of binary search – a commonly used technique to search for an item in database. This binary search technique allows the window increase to be logarithmic; it increases faster when the target rate is far away from the current transmission rate, but slows down as the current transmission rate gets closer to the target. This feature ensures the stability of control while allowing the protocol to become friendlier to existing TCP traffic. If you always increase the window faster, you may solve the *efficiency* problem. But at the same time, you don't want to starve out other traffic on the same network links. As your neighbors might be downloading music using the regular TCP on the same links at the same time, you don't want to squash out their transfers. So the bottom line is that you want to retain the *fairness* properties of TCP while making the protocol more scalable. So this is a tough balance. BIC achieves a good balance by increasing the window by S_{max} per RTT (i.e. more rapidely than new reno in which the window is increased by one MSS per RTT) when the window is far from W_{max} (e.g. when there are available resources in the network) and more slowly when the window approaches W_{max} (which allows to be fair to regular TCP flows).

3) Dans BIC l'augmentation de la fenêtre reste rythmée par le retour des ACKs. La connexion avec un RTT plus petit arrivera à saturer le lien de 1Gbps plus rapidement que l'autre. BIC résout le problème d'efficacité et d'équité en ce qui concerne la bande passante obtenue par des connexions sur le même chemin de bout en bout, mais ne résout pas le problème d'équité par rapport aux RTT différents. Les connexions à RTT plus petit restent avantagées.
4) The cubic function ensures the intra-protocol fairness among the competing flows of the same protocol. To see this, suppose that two flows are competing on the same end-to-end path. The two flows converge to a fair share since they drop by the same multiplicative factor β – so a flow with larger W_{max} will reduce more, and the growth function allows the flow with larger W_{max} will increase more slowly – K is larger as W_{max} is larger. (K is the time period for the window to reach Wmax after a loss if no toher loss occured). Thus, the two flows eventually converge to the same window size. The function also offers a good RTT fairness property because the window growth rate is dominated by t, the elapsed time. This ensures linear RTT fairness since any competing flows with different RTT will have the same t after a synchronized packet loss.

Question 7 :

1) The packet pair property of FIFO-queueing networks predicts the difference in arrival times of two packets of the same size traveling from the same source to the same destination: $t_r^1 - t_r^0 = max(s/B, t_e^1 - t_e^0)$ where t_r^0 and $t_r^1$are the arrival times of the first and second packets respectively at the destination, t_e^0 and t_e^1 are the transmission times of the first and second packets respectively, s is the size of the second packet, and B is the bandwidth of the bottleneck link.

The intuitive rationale for this equation is that if two packets are sent close enough together in time to cause the packets to queue together at the bottleneck link ($s/B > t_e^1 - t_e^0$), then the packets will arrive at the destination with the same spacing ($t_r^1 - t_r^0$) as when they exited the bottleneck link (s/B). The spacing will remain the same because the packets are the same size and no link downstream of the bottleneck link has a lower bandwidth than the bottleneck link (as shown in the Figure in the exam text).

Some additional details (outside the exam scope): this property makes several assumptions that may not hold in practice. First, it assumes that the two packets queue together at the bottleneck link and at no later link. This could by violated by other packets queueing between the two packets at the bottleneck link, or packets queueing in front of the first, the second or both packets downstream of the bottleneck link. If any of these events occur, then Equation 1 above does not hold.

In addition, the packet pair property assumes that the two packets are sent close enough in time that they queue together at the bottleneck link. This is a problem for very high bandwidth bottleneck links and/or for passive measurement. For example, from Equation 1, to cause queueing between two 1500 byte packets at a 1Gb/s bottleneck link, they would have to be transmitted no more than 12 microseconds apart. An active technique is more likely than a passive one to satisfy this assumption because it can control the size and transmission times of its packets.

Another assumption of the packet pair property is that the bottleneck router uses FIFO-queueing. If the router uses fair queueing, then packet pair measures the available bandwidth of the bottleneck link.

Finally, the packet pair property assumes that transmission delay is proportional to packet size and that routers are store-and-forward. The assumption that transmission delay is proportional to packet size may not be true if, for example, a router manages its buffers in such a way that a 128 byte packet is copied more than proportionally faster than a 129 byte packet. However, this effect is usually small enough to be ignored. The assumption that routers are store-and-forward (they receive the last bit of the packet before forwarding the first bit) is almost always true in the Internet.

2) Using the packet pair property ($s/B > t_e^1 - t_e^0$), we can solve the equation above for B, the bandwidth of the bottleneck link: $B = s/(t_r^1 - t_r^0)$.

3) If network routers implement FQ, PP allows to estimate the bandwidth *available* for the source. It is an incentive for intelligent congestion control because the source can adapt to this rate without being worried about fairness that will be ensured by FQ in the routers.